

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«РОССИЙСКИЙ ГОСУДАРСТВЕННЫЙ
ПЕДАГОГИЧЕСКИЙ УНИВЕРСИТЕТ им. А. И. ГЕРЦЕНА»

Институт информационных технологий и технологического образования
Кафедра информационных технологий и электронного обучения

Основная профессиональная образовательная программа
Направление подготовки 09.03.01 Информатика и вычислительная техника
Направленность (профиль) «Технологии разработки программного обеспечения»
форма обучения – очная

Курсовая работа

по дисциплине «Пакеты прикладных программ для статистической
обработки и анализа данных»

Использование программы KNIME для прогноза количества разводов в 2030
году

Обучающейся 3 курса
_____ Гиниятуллиной Юлии Сергеевны

Руководитель:
к.п.н, доцент
_____ Гончарова С.В.

«_____» _____ 2024 г.

Санкт-Петербург
2024

ОГЛАВЛЕНИЕ

ВВЕДЕНИЕ.....	3
Глава 1. Теоретическая часть.....	5
1.1 Анализ предметной области.....	5
1.2 Выбор среды для моделирования.....	8
1.3 Проведение регрессионного анализа в MS Excel.....	9
Глава 2. Практическая часть.....	17
ЗАКЛЮЧЕНИЕ.....	19
ЛИТЕРАТУРА.....	21
ПРИЛОЖЕНИЕ А.....	24
ПРИЛОЖЕНИЕ Б.....	25
ПРИЛОЖЕНИЕ В.....	26
ПРИЛОЖЕНИЕ Г.....	27

ВВЕДЕНИЕ

В последние десятилетия тема разводов стала одной из наиболее актуальных в области социальных наук [9]. Статистические данные показывают, что количество разводов растет во многих странах, что вызывает серьезные последствия как для индивидуумов, так и для общества в целом. Разводы могут оказывать негативное влияние на эмоциональное состояние, финансовое положение и социальные связи участников, особенно когда речь идет о детях [8, 11]. **Актуальность работы** заключается в использовании платформы интеллектуальной аналитики данных для проведения регрессионного анализа и прогнозирования будущих тенденций разводов, которые представляют собой важные задачи для социологов, психологов и экономистов.

Актуальность темы курсовой работы определила предмет, цель и задачи исследования.

Настоящая работа посвящена прогнозированию количества разводов.

Предмет исследования — анализ статистики разводов с использованием исторических данных средствами платформы для аналитики данных и машинного обучения KNIME.

Целью курсовой работы является прогнозирование количества разводов на 2030 год с применением методов регрессионного анализа в KNIME.

Реализация данной цели обусловила необходимость решения следующих **задач**:

- провести анализ научной литературы, интернет-ресурсов по теме работы;
- провести подготовительные расчеты в программе MS Excel;
- провести анализ программ для статистической обработки и анализа данных;
- разработать прогноз количества разводов на 2030 год в программе KNIME, представить его описание, сравнить с результатами расчетов Excel.

Практическая значимость исследования заключается в приобретении навыков работы с программным обеспечением (KNIME) для прогнозирования будущих тенденций, развитии математического мышления, расширении креативных возможностей, а также возможности применения результатов исследования в сферах социальных наук: психологии, и т.д.

Курсовая работа на тему: «Использование программы KNIME для прогноза количества разводов в 2030 году» состоит из введения, двух глав и заключения; содержит 23 страницы, 6 рисунков, 3 таблицы, библиографический список, содержащий 15 источников, четыре приложения.

Глава 1. Теоретическая часть

1.1 Анализ предметной области

Семья как социальная единица всегда была предметом всестороннего изучения и обсуждения. Брак представляет собой одно из важнейших отношений в обществе, которое сопровождается как радостью, так и проблемами. Однако в современном мире наблюдается устойчивый рост числа разводов, ставящий под сомнение устойчивость семейных ценностей. Этот феномен затрагивает не только отдельных людей, но и общество в целом, приводя к разрушению семейных уз, эмоциональным страданиям и даже экономическим последствиям. Прогнозирование разводов стало важной задачей для социологов, психологов и специалистов в области семейных отношений, позволяя выявить факторы, влияющие на стабильность брака.

Среди наиболее распространенных причин для развода россияне назвали бедность (33%), взаимное непонимание (15%), неверность одного из партнеров (14%), бытовые проблемы (10%), а также несовместимость характеров и пьянство (по 8%) [1, 3, 9].

Таблица статистики данных, выбранная для курсовой работы, расположена в приложении А [2, 4].

Для прогнозирования разводов был выбран регрессионный анализ.

Регрессионный анализ – один из основных методов современной математической статистики, позволяющий аналитически представить связь между переменными объекта [6]. Если корреляционный анализ позволяет установить существует ли факт зависимости между парами наблюдений, то регрессионный анализ дает целый арсенал методов построения соответствующих зависимостей.

В прикладных задачах статистического анализа зависимость между входными переменными $x_1, x_2, x_3, \dots, x_n$ и выходной переменной Y носит

стохастический характер. При изучении стохастических зависимостей в задачах техники, экономики и т. д. одним из главных моментов является установление вида зависимости Y от $x_1, x_2, x_3, \dots, x_n$, т.е. вида уравнения регрессии. Это связано прежде всего с необходимостью прогнозирования исследуемых процессов.

Установление формы зависимости, оценки функции регрессии и ее параметров являются задачами регрессионного анализа.

В регрессионном анализе изучаются модели вида

$$Y = \varphi(x) + \varepsilon, \quad (1)$$

где x – неслучайная независимая переменная, называемая фактором;

Y – случайная зависимая переменная (результатирующий признак);

ε – случайная переменная, характеризующая отклонение от линии регрессии (остаточная переменная).

Задача регрессионного анализа состоит в определении функции φ , ее параметров и дальнейшего статистического исследования полученного уравнения регрессии.

При помощи одного только регрессионного анализа не представляется возможным построить прогноз количества разводов на несколько лет вперед. На развод влияет не только год, но и экономика, политическая ситуация в стране или в мире, эпидемии, и т.д. Но можно отследить тенденцию роста или спада по взятым данным.

Необходимо определить коэффициент автокорреляции первого порядка по формулам (2 – 4):

$$\bar{y}_1 = \frac{\sum_{t=2}^n y_t}{n-1} \quad (2)$$

$$\bar{y}_2 = \frac{\sum_{t=2}^n y_{t-1}}{n-1} \quad (3)$$

$$r_1 = \frac{\sum_{t=2}^n (y_t - \bar{y}_1) \cdot (y_{t-2} - \bar{y}_2)}{\sqrt{\sum_{t=2}^n (y_t - \bar{y}_1)^2 \cdot \sum_{t=1}^n (y_{t-1} - \bar{y}_2)}} \quad (4)$$

1.2 Выбор среды для моделирования

Регрессионный анализ был проведен в программе KNIME [5]. Выбор данной программы обусловлен возможностью загрузки данных из Excel, открытым исходным кодом; богатым выбором параметров и функций для анализа; отличной оптимизацией для работы с большими объемами данных. Более подробное обоснование выбора этой программы представлено в таблице 1 [5,].

Из возможных версий программы KNIME была выбрана наиболее актуальная версия 5.3.2., так как данная версия обладает наиболее совершенным функционалом и имеет малое количество несовершенств [].

Таблица 1. Сравнительная таблица программ для статистической обработки и анализа данных

Название программы	Доступность	Поддержка внешних таблиц	Загрузка / выгрузка данных	Построение графиков и диаграмм	Богатый набор функций для анализа данных	Достаточное количество документации и ресурсов
KNIME	Бесплатная, с открытым исходным кодом	+	+	+	+	+
Statgraphics	Платная	+	+	+	+	-
Minitab	Платная	+	+	+	+	+
OpenEpi	Бесплатная, с открытым исходным кодом	+	-	+	+	-

1.3 Проведение регрессионного анализа в MS Excel

Имеются данные о количестве разводов с 1980 по 2022 годы, с интервалом в 2 года.

Для выявления тенденции в эти годы требуется:

- 1) построить график временного ряда;
- 2) рассчитать коэффициент автокорреляции первого порядка;
- 3) обосновать выбор типа уравнения тренда и рассчитать его параметры.

Для проведения регрессионного анализа требуется:

- 1) рассчитать параметры уравнения регрессии методом наименьших квадратов;
- 2) оценить качество уравнения с помощью средней ошибки аппроксимации;
- 3) найти коэффициент эластичности;
- 4) оценить тесноту связи между переменными с помощью показателей корреляции и детерминации;
- 5) оценить значимость коэффициентов корреляции и регрессии по критерию t-Стюдента при уровне значимости $\alpha = 0.05$;
- 6) охарактеризовать статистическую надежность результатов регрессионного анализа с использованием критерия F-Фишера при уровне значимости $\alpha = 0.05$;
- 7) определить прогнозное значение результативного признака, если возможное значение факторного признака составит 1.2 от его среднего уровня по совокупности.

Решение задачи выявления тенденции с 1980 по 2022 годы:

- 1) Рассмотрим систему координат $Y_0 t$, где Y_t — валовой сбор, t — порядковый номер года и нанесем в ней данные примера на график, изображенный на рисунке 1.




Рисунок 1. График временного ряда с линией тренда.

2) Для определения коэффициента автокорреляции первого порядка необходимо заполнить вспомогательную таблицу, которая расположена в Приложении Б. После заполнения мы можем рассчитать коэффициент автокорреляции первого порядка по следующим формулам (5 - 7):

$$\overline{y_1} = \frac{\sum_{t=2}^n y_t}{n-1} \quad (5)$$

$$\overline{y_2} = \frac{\sum_{t=2}^n y_{t-1}}{n-1} \quad (6)$$


$$r_1 = \frac{\sum_{t=2}^n (y_t - \overline{y_1}) \cdot (y_{t-1} - \overline{y_2})}{\sqrt{\sum_{t=2}^n (y_t - \overline{y_1})^2 \cdot \sum_{t=2}^n (y_{t-1} - \overline{y_2})^2}} \quad (7)$$

После проведения расчетов, получаем, что $\overline{y_1} = 624.1175$,
 $\overline{y_2} = 619.2518, r_1 = 0.215773$.

3) Полученное значение коэффициента автокорреляции и графическое изображение временного ряда позволяют сделать вывод о том, что количество разводов в год содержит тенденцию, относительно близкую к линейной. Поэтому для моделирования его тенденции используем линейную функцию $y = a + bt$.

Для расчета параметров a и b используем метод наименьших

квадратов, для чего необходимо составить и решить систему уравнений, представленную на рисунке 2.



$$\begin{cases} na + b \sum t = \sum y \\ a \sum t + b \sum t^2 = \sum yt \end{cases}$$

Рисунок 2. Система линейных уравнений для метода наименьших квадратов.

Необходимая вспомогательная таблица расположена в приложении В.

В результате решения системы (рис. 2) получают формулы (8) и (9) для нахождения параметров a и b :

$$b = \frac{\overline{y \cdot t} - \bar{y} \cdot \bar{t}}{\overline{t^2} - \bar{t}^2} \quad (8)$$

$$a = \bar{y} - b \cdot \bar{t} \quad (9)$$

В итоге получим линейную функцию (10):

$$\overline{y_t} = 579,5931 + 3,700156 \cdot t \quad (10)$$

Вывод: в среднем ежегодно количество разводов в России 1980 – 2022 г.г. увеличивалось на 3,700156 тыс.

Проведение регрессионного анализа:

1) Параметры уравнения регрессии находим методом наименьших квадратов, путем составления и решения нормальных уравнений регрессии. Для проведения всех расчетов была построена вспомогательная таблица, представленная в приложении Г.

Воспользовавшись вспомогательной таблицей, были найдены параметры уравнения регрессии по формулам (11 - 12), которые получаются из системы нормальных уравнений:

$$b_1 = \frac{\overline{X \cdot Y} - \bar{X} \cdot \bar{Y}}{\overline{X^2} - (\bar{X})^2} \quad (11)$$

$$b_0 = \bar{Y} - b_1 \cdot \bar{X} \quad (12)$$

Таким образом, проведя некоторые расчеты, уравнение регрессии (13) имеет вид:

$$y' = 1,8502 \cdot x - 3080,1 \quad (13)$$

Коэффициент регрессии показывает, что ежегодно количество разводов в среднем увеличивается на 1,85 тысяч.

2) Качество уравнения регрессии оценивается с помощью средней ошибки аппроксимации (14):

$$\bar{A} = \frac{1}{n} \times \sum_i^n \left| \frac{y_i - y'_i}{y_i} \right| \times 100\% \quad (14)$$

$$\bar{A} = 0,071221307 = 7,12\%$$

3) При линейной форме связи средний коэффициент эластичности находится по формуле (15):

$$\mathcal{E} = b_1 \times \frac{\bar{X}}{\bar{Y}}, \quad (15)$$

где $\bar{X}$ и $\bar{Y}$ — средние значения признаков.

Проведя расчеты, получаем, что $\mathcal{E} = 5,95$. Значение коэффициента эластичности показывает, что ежегодно количество разводов в среднем возрастает почти на 6%.

4) При линейной зависимости, степень тесноты связи между переменными X и Y определяется с помощью коэффициента корреляции (16):

$$r = \frac{\overline{X \cdot Y} - \bar{X} \cdot \bar{Y}}{\sigma_x \cdot \sigma_y}, \quad (16)$$

где σ_x и σ_y — средние квадратические отклонения по X и Y . Они вычисляются по следующим формулам (17 - 18):

$$\sigma_x = \sqrt{X^2 - \bar{X}^2} \quad (17)$$

$$\sigma_y = \sqrt{Y^2 - \bar{Y}^2} \quad (18)$$

Значение коэффициента корреляции $r \approx 0,33$ не близко к единице, что говорит о не очень тесной связи между признаками.

Коэффициент детерминации $r^2 = 0,33^2 = 0,1089$ показывает, что 11% различий в количестве разводов в год объясняется годом, а остальные 89% – другими, неучтенными факторами (экономические и политические ситуации в стране, в мире и т.д.)

5) Так как исходные данные являются выборочными, то необходимо оценить существенность и значимость величины коэффициента корреляции.

Выдвигаем нулевую гипотезу H_0 : коэффициента корреляции в генеральной совокупности равен нулю, и изучаемый фактор не оказывает существенного влияния на результативный признак.

Для проверки нулевой гипотезы применим t-критерий Стьюдента.

Найдем расчетное значение t-критерия по формуле 19:

$$t_{\text{расч}} = \frac{|r|}{\sqrt{\frac{1-r^2}{n-2}}} \quad (19)$$

Критическое значение t находится по таблице 2.

Q	Вероятность ошибки			Q	Вероятность ошибки		
	0,05	0,01	0,001		0,05	0,01	0,001
1	12,71	63,66	636,62	21	2,08	2,83	3,82
2	4,30	9,93	31,60	22	2,07	2,82	3,79
3	3,18	5,84	12,94	23	2,07	2,81	3,77
4	2,78	4,60	8,61	24	2,06	2,80	3,75
5	2,57	4,03	6,86	25	2,06	2,79	3,73
6	2,45	3,71	5,96	26	2,06	2,78	3,71
7	2,37	3,50	5,41	27	2,05	2,77	3,69
8	2,31	3,36	5,04	28	2,05	2,76	3,67
9	2,26	3,25	4,78	29	2,04	2,76	3,66
10	2,23	3,17	4,59	30	2,04	2,75	3,65
11	2,20	3,11	4,44	40	2,02	2,70	3,55
12	2,18	3,06	4,32	50	2,01	2,68	3,50
13	2,16	3,01	4,22	60	2,00	2,66	3,46
14	2,15	2,98	4,14	80	1,99	2,64	3,42
15	2,13	2,95	4,07	100	1,98	2,63	3,39
16	2,12	2,92	4,02	120	1,98	2,62	3,37
17	2,11	2,90	3,97	200	1,97	2,60	3,34
18	2,10	2,88	3,92	500	1,96	2,59	3,31
19	2,09	2,86	3,88	1000	1,96	2,58	3,29
20	2,09	2,85	3,85	(∞)			

Таблица 2. Таблица t-критерия Стьюдента.

Уровень значимости = 0.05, а число степеней свободы $k = n - 2 = 20$.

Для двусторонней критической области $t_{кр} = 2,09$. Расчетное значение критерия равно $t_{расч} = 1,55$.

Сравним $t_{расч}$ и $t_{кр}$. Так как $t_{расч} < t_{кр}$, то нулевая гипотеза частично подтверждается. Коэффициент корреляции существенно отличен от нуля в генеральной совокупности. Значит, годы оказывают статистически не существенное, но значительное влияние на количество разводов в год.

Статистическая значимость коэффициента регрессии также проводится с использованием t-критерия Стьюдента.

Расчетное значение критерия находится по формулам (20 – 21):

$$t_{расч} = \frac{b_1}{m_{b_1}} \quad (20)$$

$$m_{b_1} = \sqrt{\frac{\sum(y - y')^2}{(n-2) \cdot \sum(x - \bar{X})^2}} = \sqrt{\frac{\sum(y - y')^2}{(n-2) \cdot \sigma_x^2 \cdot n}} \quad (21)$$

Критическое значение t также равно 2,16. Расчетное значение

критерия равно 1,55. Так как $t_{\text{расч}} < t_{\text{кр}}$, то коэффициент регрессии статистически важен. Частично подтверждается вывод о значимости года на количество разводов в год.

6) Статистическая надежность уравнения регрессии проверяется с использованием критерия F-Фишера.

При применении линейного уравнения регрессии расчетное F вычисляется по формуле 22:

$$F_{\text{расч}} = \frac{r^2}{1-r^2} \cdot (n - 2) \quad (22)$$

При уровне значимости $\alpha = 0,05$ и числе степеней свободы 20 по таблице 3 находится критическое значение F-критерия. $F_{\text{кр}} = F_{0.05; 1, 20} = 4,35$. Расчетное значение равно 2,4. Так как $F_{\text{кр}} > F_{\text{расч}}$, то уравнение регрессии статистически не очень значимое и надежное, потому что на зависимость между годом и количеством разводов в год влияет еще ряд различных факторов. Однако, если не брать в расчет годы с наибольшим количеством разводов по причине кризисов, бедности, болезней, войн и т.д., то прослеживается общая тенденция возрастания числа разводов.

Критические точки распределения F Фишера-Снедекора
(k_1 - число степеней свободы большей дисперсии, k_2 - число степеней свободы меньшей дисперсии)

Уровень значимости $\alpha = 0,05$

$k_2 \backslash k_1$	1	2	3	4	5	6	7	8	9	10	11	12	16	20	24	30	50	100	∞
1	161	200	216	225	230	236	237	239	241	242	243	244	246	248	249	250	252	253	254
2	18,51	19,00	19,16	19,25	19,30	19,33	19,36	19,37	19,38	19,39	19,40	19,41	19,43	19,44	19,45	19,46	19,47	19,49	19,50
3	10,13	9,55	9,28	9,12	9,01	8,94	8,88	8,84	8,81	8,78	8,76	8,74	8,69	8,66	8,64	8,62	8,58	8,56	8,53
4	7,71	6,94	6,59	6,39	6,26	6,16	6,09	6,04	6,00	5,96	5,93	5,91	5,84	5,80	5,77	5,74	5,70	5,66	5,63
5	6,61	5,79	5,41	5,19	5,05	4,95	4,88	4,82	4,78	4,74	4,70	4,68	4,60	4,56	4,53	4,50	4,44	4,40	4,36
6	5,99	5,14	4,76	4,53	4,39	4,28	4,21	4,15	4,10	4,06	4,03	4,00	3,92	3,87	3,84	3,81	3,75	3,71	3,67
7	5,59	4,74	4,35	4,12	3,97	3,87	3,79	3,73	3,68	3,63	3,60	3,57	3,49	3,44	3,41	3,38	3,32	3,28	3,23
8	5,32	4,46	4,07	3,84	3,69	3,58	3,50	3,44	3,39	3,34	3,31	3,28	3,20	3,15	3,12	3,08	3,03	2,98	2,93
9	5,12	4,26	3,86	3,63	3,48	3,37	3,29	3,23	3,18	3,13	3,10	3,07	2,98	2,93	2,90	2,86	2,80	2,76	2,71
10	4,96	4,10	3,71	3,48	3,33	3,22	3,14	3,07	3,02	2,97	2,94	2,91	2,82	2,77	2,74	2,70	2,64	2,59	2,54
11	4,84	3,98	3,59	3,36	3,20	3,09	3,01	2,95	2,90	2,86	2,82	2,79	2,70	2,65	2,61	2,57	2,50	2,45	2,40
12	4,75	3,88	3,49	3,26	3,11	3,00	2,92	2,85	2,80	2,76	2,72	2,69	2,60	2,54	2,50	2,46	2,40	2,35	2,30
13	4,67	3,80	3,41	3,18	3,02	2,92	2,84	2,77	2,72	2,67	2,63	2,60	2,51	2,46	2,42	2,38	2,32	2,26	2,21
14	4,60	3,74	3,34	3,11	2,96	2,85	2,77	2,70	2,65	2,60	2,56	2,53	2,44	2,39	2,35	2,31	2,24	2,19	2,13
15	4,54	3,68	3,29	3,06	2,90	2,79	2,70	2,64	2,59	2,55	2,51	2,48	2,39	2,33	2,29	2,25	2,18	2,12	2,07
16	4,49	3,63	3,24	3,01	2,85	2,74	2,66	2,59	2,54	2,49	2,45	2,42	2,33	2,28	2,24	2,20	2,13	2,07	2,01
17	4,45	3,59	3,20	2,96	2,81	2,70	2,62	2,55	2,50	2,45	2,41	2,38	2,29	2,23	2,19	2,15	2,08	2,02	1,96
18	4,41	3,55	3,16	2,93	2,77	2,66	2,58	2,51	2,46	2,41	2,37	2,34	2,25	2,19	2,15	2,11	2,04	1,98	1,92
19	4,38	3,52	3,13	2,90	2,74	2,63	2,55	2,48	2,43	2,38	2,34	2,31	2,21	2,15	2,11	2,07	2,00	1,94	1,88
20	4,35	3,49	3,10	2,87	2,71	2,60	2,52	2,45	2,40	2,35	2,31	2,28	2,18	2,12	2,08	2,04	1,96	1,90	1,84
22	4,30	3,44	3,05	2,82	2,66	2,55	2,47	2,40	2,35	2,30	2,26	2,23	2,13	2,07	2,03	1,98	1,91	1,84	1,78
24	4,26	3,40	3,01	2,78	2,62	2,51	2,43	2,36	2,30	2,26	2,22	2,18	2,09	2,02	1,98	1,94	1,86	1,80	1,73
26	4,22	3,37	2,98	2,74	2,59	2,47	2,39	2,32	2,27	2,22	2,18	2,15	2,05	1,99	1,95	1,90	1,82	1,76	1,69
28	4,20	3,34	2,95	2,71	2,56	2,44	2,36	2,29	2,24	2,19	2,15	2,12	2,02	1,96	1,91	1,87	1,78	1,72	1,65
30	4,15	3,30	2,90	2,67	2,51	2,40	2,32	2,25	2,19	2,14	2,10	2,07	1,97	1,91	1,86	1,82	1,74	1,67	1,59
36	4,11	3,26	2,86	2,63	2,48	2,36	2,28	2,21	2,15	2,10	2,06	2,03	1,93	1,87	1,82	1,78	1,69	1,62	1,55
40	4,08	3,23	2,84	2,61	2,45	2,34	2,25	2,18	2,12	2,07	2,03	2,00	1,90	1,84	1,79	1,74	1,66	1,59	1,51
60	4,00	3,15	2,76	2,52	2,37	2,25	2,17	2,10	2,04	1,99	1,95	1,92	1,81	1,75	1,70	1,65	1,56	1,48	1,39
100	3,94	3,09	2,70	2,46	2,30	2,19	2,10	2,03	1,97	1,92	1,88	1,85	1,75	1,68	1,63	1,57	1,48	1,39	1,28
200	3,89	3,04	2,65	2,41	2,26	2,14	2,05	1,98	1,92	1,87	1,83	1,80	1,69	1,62	1,57	1,52	1,42	1,32	1,19
∞	3,84	2,99	2,60	2,37	2,21	2,09	2,01	1,94	1,88	1,83	1,79	1,75	1,64	1,57	1,52	1,46	1,35	1,24	1,00

Таблица 3. Критические точки распределения F-Фишера

7) Прогнозное значение результативного признака определяется путем подстановки в уравнение регрессии прогнозного или возможного значения факторного признака (x_n).

По условию $x_p = 2030$

Тогда $y_p = b_0 + b_1 \cdot x_p \approx 676$


Это означает, что в 2030 году возможное количество разводов составляет 676 тысяч.

Глава 2. Практическая часть

В программном обеспечении KNIME необходимо провести регрессионный анализ с данными, которые использовались ранее в программе MS Excel [10, 11]. Также необходимо провести прогноз на 2030 год.

Для начала необходимо использовать данные из Excel. Для этого воспользуемся узлом “Excel Reader”. Он предназначен для импорта данных из файлов Excel (форматы .xls и .xlsx) в рабочее пространство. Этот узел позволяет загружать таблицы и работать с данными, хранящимися в этих файлах.

Затем необходимо воспользоваться узлом “Linear Regression Learner”. Он используется для обучения модели линейной регрессии на основе предоставленных данных. В данном случае этот узел помогает создать математическую модель, которая будет прогнозировать зависимость между независимой переменной (годами) и зависимой переменной (количеством разводов). Результат регрессионного анализа можно увидеть на рисунке 3.



The screenshot shows the output of the 'Linear Regression Learner' node in KNIME. The interface includes tabs for '1: Model for Predictor', '2: Coefficients and Statistics' (which is active), and 'Flow Variables'. Below the tabs, it indicates 'Rows: 2 | Columns: 5'. There are buttons for 'Table' and 'Statistics'. The table itself has columns: #, RowID, Variable, Coeff. (Coefficient), Std. Err. (Standard Error), t-value, and P>|t| (P-value). The data is as follows:

#	RowID	Variable	Coeff.	Std. Err.	t-value	P> t
1	Row1	x, год	1.85	1.195	1.548	0.137
2	Row2	Intercept	-3,079.861	2,391.599	-1.288	0.213

Рисунок 3. Результат работы узла “Linear Regression Learner”

Целью курсовой работы является прогноз количества разводов на 2030 год. Однако имеющаяся таблица с данными не имеет такое значение. Тогда добавим это значение при помощи узла “Table Creator”. Добавим значение 2030 и сделаем его целым числом. Это можно увидеть на рисунке 4.

Rows: 1 Columns: 1			
☐	#	RowID	x, год Number (integer)
☐	1	Row0	2030

Рисунок 4. Содержимое узла “Table Creator”.

Теперь необходимо построить прогноз на 2030 год. Для этого необходимо использовать узел “Regression Predictor”, который предназначен для прогнозирования. Он принимает на вход два узла данных - тот, который умеет считать регрессионный анализ и данные, для которых необходимо построить прогноз. Поэтому соединяем его с узлами “Linear Regression Learner” и “Table Creator”.

Итоговая схема проведения регрессионного анализа в программном обеспечении KNIME отображена на рисунке 5.



Рисунок 5. Схема проведения регрессионного анализа и прогнозирования в программе KNIME.

В итоге получаем, что в 2030 году, по версии программы KNIME, будет приблизительно 675,797 тысяч разводов. Этот вывод изображен на рисунке 6.

Rows: 1 Columns: 2				Table	Statistics		
☐	#	RowID	x, год Number (integer)		Prediction (y, количество разводов, тыс.) Number (double)		
☐	1	Row0	2030		675.797		

Рисунок 6. Результат работы узла “Regression Predictor”

ЗАКЛЮЧЕНИЕ

В рамках курсовой работы была поставлена цель — разработать прогноз количества разводов на 2030 год с использованием методов регрессионного анализа. Для достижения этой цели были выполнены следующие задачи: анализ научной литературы и интернет-ресурсов по теме, проведение расчетов в программе MS Excel, анализ программ для статистической обработки данных, а также построение прогноза с использованием программы KNIME.

В программе MS Excel был проведен расчет прогноза с использованием линейной регрессии, который дал значение 675,80 тысяч разводов на 2030 год. Параллельно был построен аналогичный прогноз в программе KNIME, которая является мощным инструментом для анализа данных и предоставляет возможность работы с более сложными моделями и алгоритмами. Результат, полученный в KNIME, составил 675,80 тысяч разводов, что практически совпадает с результатом, полученным в Excel.

Сравнение этих двух результатов показывает, что оба метода дают практически одинаковые значения прогноза. Разница в результатах минимальна (разница составляет лишь 0,0003 тысяч разводов), что подтверждает высокую точность и надежность как Excel, так и KNIME для выполнения задачи линейного регрессионного анализа. Разница в значениях прогноза может быть обусловлена особенностями работы алгоритмов в Excel и KNIME, а также небольшими погрешностями, которые неизбежны при использовании любых инструментов для анализа данных.

Необходимо уточнить, что, несмотря на то что количество разводов не сильно зависит от года, выявлена общая тенденция повышения количества разводов. Помимо года на разводы влияют такие факторы, как пандемии, экономические и политические ситуации в стране, экономические и политические ситуации в мире. Например, рекордное количество разводов в России было зафиксировано в 2002 году. Это обусловлено экономическими изменениями[11], увеличением числа женщин на рынке труда, а также тем,

что количество предрассудков, касаемо разводов, уменьшилось. Более того, упростился процесс расторжения брака, что дало “застоявшимся” супругам шанс на построение счастливой семьи. Или, например, второй год по количеству разводов – 2008. В этот год, помимо общей тенденции возрастания числа разводов, повлиял мировой экономический кризис.

ЛИТЕРАТУРА

1. Статистика браков и разводов. - Текст : электронный // Gogov.ru : [сайт]. - 2024. - URL: <https://clck.ru/3FHrJC> (дата обращения: 28.10.2024).
2. Демографический ежегодник России : Браки и разводы. - Текст : электронный // Росстат : официальный сайт. - 2007. - URL: https://rosstat.gov.ru/bgd/regl/B07_16/IssWWW.exe/Stg/03-01.htm (дата обращения: 28.10.2024).
3. Девятый ежегодный демографический доклад “Население России”. - Текст : электронный // Демоскоп Weekly : официальный сайт. - 2001. - URL: https://www.demoscope.ru/weekly/knigi/ns_r01/razdel2g2_3.html (дата обращения: 29.10.2024).
4. Статистика: Число браков и разводов. - Текст : электронный // Руксперт : официальный сайт. - 2020. - URL: <https://clck.ru/3FHrKV> (дата обращения: 29.10.2024).
5. **Чучуева, И.** Сравнение программных продуктов для анализа данных: R, MATLAB, SciPy, MS Excel, SAS, SPSS, Stata. - Текст : электронный // Математическое бюро : [сайт]. - 2012. - URL: <https://clck.ru/3FHsbq> (дата обращения: 13.10.2024)
6. **Регрессионный анализ в почвоведении** : учебное пособие / Е. В. Шеин, М. А. Мазиров, А. А. Корчагин [и др.]. - Владимир : Издательство ВлГУ, 2016. - 88 с. - ISBN 978-5-9984-0712-3. - Текст : непосредственный.
7. **Корреляционно-регрессионный анализ связи показателей коммерческой деятельности с использованием программы Excel** : учебное пособие / В. Р. Бараз. - Екатеринбург : ГОУ ВПО «УГТУ–УПИ», 2005. – 102 с. - Текст : непосредственный.
8. **Павлов, С. П.** Развод как форма психоэмоциональной депривации детей. - Текст : электронный // Семья. - URL:

- http://homekid.ru/content/docs/izdaniya/serealnui_sbornik/vse-vupyski/v2/74-93.pdf (дата обращения 21.11.2024).
9. От брака до развода: 1990-2021. - Текст : электронный // ВЦИОМ Новости : официальный сайт. - 2021. - URL: <https://wciom.ru/analytical-reviews/analiticheskii-obzor/ot-braka-do-razvoda-1990-2021> (дата обращения 11.11.2024)
10. KNIME : официальный сайт. - URL: <https://www.knime.com/> (дата обращения: 02.12.2024). - Текст : электронный.
11. KNIME Learning Center : официальный сайт. - URL: <https://www.knime.com/learning> (дата обращения: 03.12.2024). - Текст : электронный.
12. **Миличь, М.** Любовная химия: наши чувства зависят от взаимодействия гормонов. - Текст : электронный // Аргументы и факты. - 2011. - URL: <https://aif.ru/health/psychologic/23713> (дата обращения 15.12.2024)
13. **Белобродов, И. И.** Трансформация семейно-брачного поведения в России. - Текст : электронный // Демографические исследования. - 2013. - №14. - URL: https://web.archive.org/web/20150402122355/http://demographia.net/transfornaciya-semeyno-brachnogo-povedeniya-v-rossii#_ftnref14 (дата обращения: 11.12.2024).
14. **Шакало Д. Н., Гончаров А. В., Иванюга Т. В.** Основы статистического анализа : учебное пособие для вузов / Д. Н. Шакало, А. В. Гончаров, Т. В. Иванюга. - 1-е изд. - Санкт-Петербург : Лань, 2024. - 92 с. - ISBN 978-5-507-48378-5. - URL: <https://e.lanbook.com/book/380723> (дата обращения 09.11.2024). - Режим доступа: Электронно-библиотечная сеть Лань. - Текст : электронный.
15. **Волкова Н. А., Кропачева Н. Ю., Михайлова Е. Г.** Элементы математики и статистики : учебное пособие для вузов / Н. А. Волкова,

Н. Ю. Кропачева, Е. Г. Михайлова. - 2-е изд., стер. - Санкт-Петербург :
Лань, 2023. - 128 с. - ISBN 978-5-507-46535-4. - Текст :
непосредственный.

ПРИЛОЖЕНИЕ А

Год	Количество разводов
1980	580720
1982	557623
1984	573705
1986	579387
1988	573863
1990	559918
1992	639248
1994	680494
1996	562373
1998	501654
2000	627703
2002	853647
2004	635835
2006	640837
2008	703412
2010	639321
2012	644101
2014	693730
2016	608336
2018	583942
2020	564704
2022	682850

ПРИЛОЖЕНИЕ Б

t	y _t	y _{t-1}	y _t - y ₁	y _{t-1} - y ₂	(y _t - y ₁) * (y _{t-1} - y ₂)	(y _t - y ₁) ²	(y _{t-1} - y ₂) ²
1	580,72						
2	557,6	580,72	-66,5175	-38,5318	2563,040557	4424,581	1484,700345
3	573,705	557,6	-50,4125	-61,6518	3108,023316	2541,423	3800,945618
4	579,4	573,705	-44,7175	-45,5468	2036,740539	1999,657	2074,511858
5	573,863	579,4	-50,2545	-39,8518	2002,733711	2525,517	1588,166722
6	559,9	573,863	-64,2175	-45,3888	2914,756956	4123,89	2060,14403
7	639,2	559,9	15,08248	-59,3518	-895,172254	227,4811	3522,637294
8	680,5	639,2	56,38248	19,94819	1124,728375	3178,984	397,9303033
9	562,4	680,5	-61,7175	61,24819	-3780,086654	3809,053	3751,340837
10	501,7	562,4	-122,418	-56,8518	6959,657746	14986,05	3232,128246
11	627,7	501,7	3,582476	-117,552	-421,1265588	12,83414	13818,42792
12	853,6	627,7	229,4825	8,44819	1938,71167	52662,21	71,37192232
13	635,8	853,6	11,68248	234,3482	2737,767156	136,4802	54919,07438
14	640,8	635,8	16,68248	16,54819	276,0647936	278,305	273,842608
15	703,4	640,8	79,28248	21,54819	1708,393898	6285,711	464,3245128
16	639,3	703,4	15,18248	84,14819	1277,577898	230,5076	7080,91796
17	644,1	639,3	19,98248	20,04819	400,6124889	399,2994	401,9299414
18	693,7	644,1	69,58248	24,84819	1728,998622	4841,721	617,4325699
19	608,3	693,7	-15,8175	74,44819	-1177,586025	250,1941	5542,533065
20	583,9	608,3	-40,2175	-10,9518	440,4546603	1617,449	119,9421318
21	564,7	583,9	-59,4175	-35,3518	2100,516984	3530,442	1249,750437
22	682,9	564,7	58,78248	-54,5518	-3206,690444	3455,38	2975,899922
Сумма	13687,19	13004,29			23838,11743	111517,2	109447,9526

ПРИЛОЖЕНИЕ В

t	y	t	y*t	t^2	y_t
1	580,72	1	580,72	1	583,2932727
2	557,6	2	1115,2	4	586,9934286
3	573,705	3	1721,115	9	590,6935844
4	579,4	4	2317,6	16	594,3937403
5	573,863	5	2869,315	25	598,0938961
6	559,9	6	3359,4	36	601,7940519
7	639,2	7	4474,4	49	605,4942078
8	680,5	8	5444	64	609,1943636
9	562,4	9	5061,6	81	612,8945195
10	501,7	10	5017	100	616,5946753
11	627,7	11	6904,7	121	620,2948312
12	853,6	12	10243,2	144	623,994987
13	635,8	13	8265,4	169	627,6951429
14	640,8	14	8971,2	196	631,3952987
15	703,4	15	10551	225	635,0954545
16	639,3	16	10228,8	256	638,7956104
17	644,1	17	10949,7	289	642,4957662
18	693,7	18	12486,6	324	646,1959221
19	608,3	19	11557,7	361	649,8960779
20	583,9	20	11678	400	653,5962338
21	564,7	21	11858,7	441	657,2963896
22	682,9	22	15023,8	484	660,9965455
Сумма		253	160679,2	3795	
Среднее значение		11,5	7303,598	172,5	

ПРИЛОЖЕНИЕ Г

№	x	y	x ²	y ²	xy	y'	y-y'	(y-y') ²	A
1	1980	580,7	3920400	337212,49	1149786	583,2899	-2,58987	6,707445	0,004459917
2	1982	557,6	3928324	310917,76	1105163,2	586,9903	-29,3903	863,7878	0,052708512
3	1984	573,705	3936256	329137,427	1138230,72	590,6907	-16,9857	288,5126	0,029606957
4	1986	579,4	3944196	335704,36	1150688,4	594,3911	-14,9911	224,7317	0,025873408
5	1988	573,863	3952144	329318,7428	1140839,644	598,0914	-24,2284	587,0176	0,042219912
6	1990	559,9	3960100	313488,01	1114201	601,7918	-41,8918	1754,926	0,074820215
7	1992	639,2	3968064	408576,64	1273286,4	605,4922	33,70777	1136,214	0,052734306
8	1994	680,5	3976036	463080,25	1356917	609,1926	71,30738	5084,742	0,104786738
9	1996	562,4	3984016	316293,76	1122550,4	612,893	-50,493	2549,545	0,089781326
10	1998	501,7	3992004	251702,89	1002396,6	616,5934	-114,893	13200,5	0,229008193
11	2000	627,7	4000000	394007,29	1255400	620,2938	7,406196	54,85175	0,011798943
12	2002	853,6	4008004	728632,96	1708907,2	623,9942	229,6058	52718,83	0,268985243
13	2004	635,8	4016016	404241,64	1274143,2	627,6946	8,105411	65,69768	0,012748365
14	2006	640,8	4024036	410624,64	1285444,8	631,395	9,405018	88,45435	0,014676994
15	2008	703,4	4032064	494771,56	1412427,2	635,0954	68,30462	4665,522	0,097106375
16	2010	639,3	4040100	408704,49	1284993	638,7958	0,504232	0,254249	0,000788724
17	2012	644,1	4048144	414864,81	1295929,2	642,4962	1,603839	2,572298	0,002490046
18	2014	693,7	4056196	481219,69	1397111,8	646,1966	47,50345	2256,577	0,06847837
19	2016	608,3	4064256	370028,89	1226332,8	649,8969	-41,5969	1730,306	0,068382291
20	2018	583,9	4072324	340939,21	1178310,2	653,5973	-69,6973	4857,719	0,1193652
21	2020	564,7	4080400	318886,09	1140694	657,2977	-92,5977	8574,34	0,163976861
22	2022	682,9	4088484	466352,41	1380823,8	660,9981	21,90187	479,6921	0,03207186
Итого	44022	13687,168	88091564	8628706,01	27394576,56				
Ср. значение	2001	622,144	4004162	392213,9095	1245208,026				0,071221307